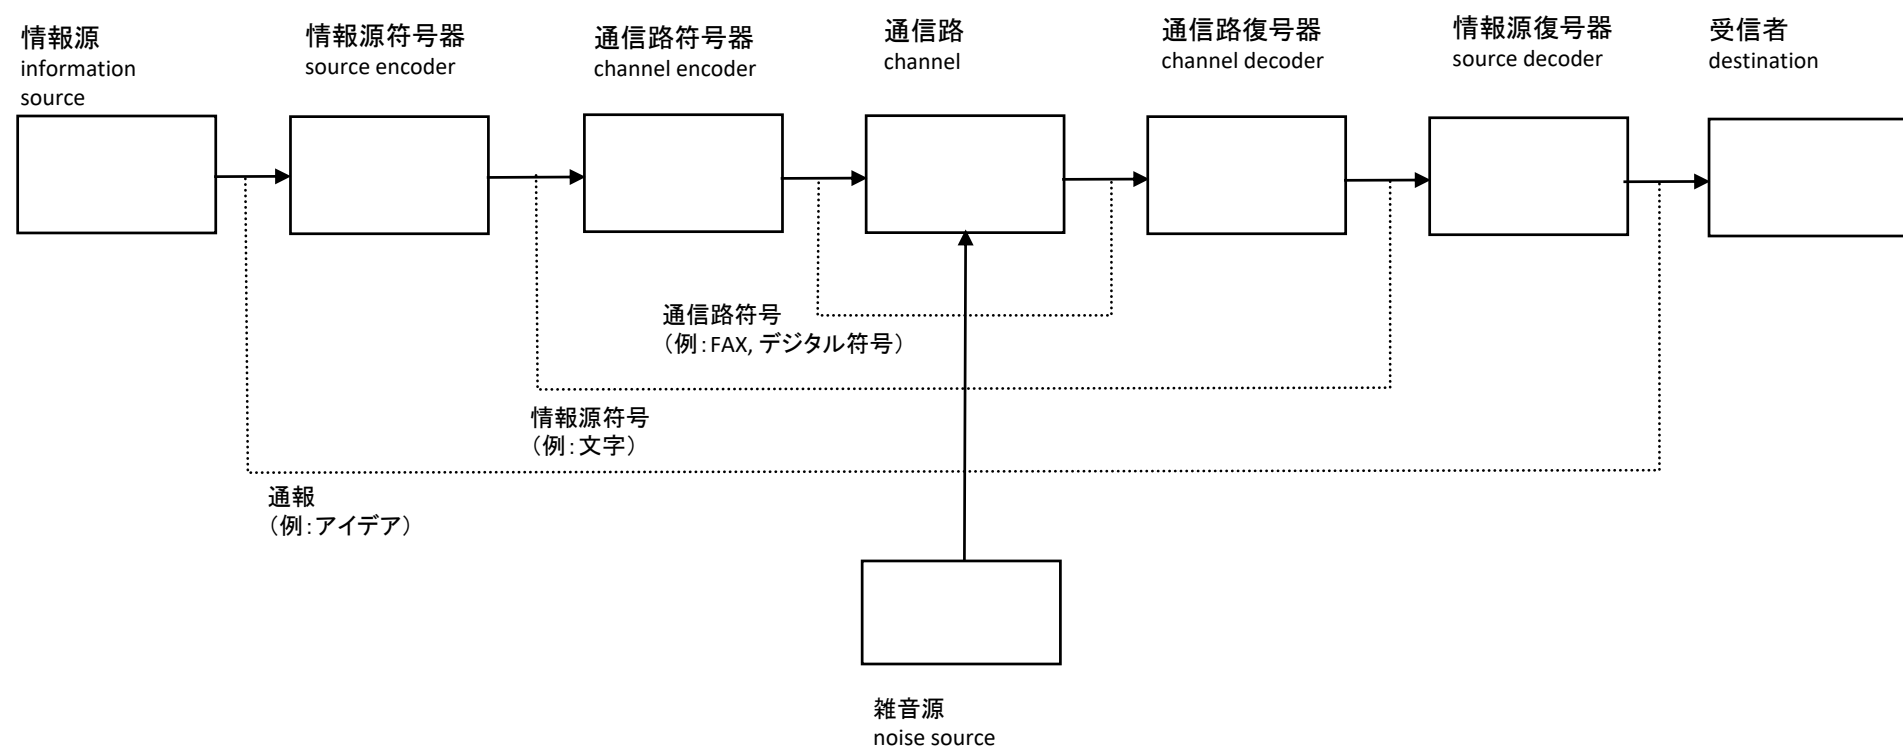


情報源符号化とその限界


本科目の構成



情報源のモデル化

情報源：確率モデルを用いてモデル化する.

(例) 人, 生命, ...



情報源モデル


情報源記号 {A, B, C, D, ...}

情報源記号の生成を説明する確率モデル



情報源符号化

情報源から発せられる情報源記号(列)を符号語列に変換する.



平均符号長

情報源

情報源符号化

$A \rightarrow 00, B \rightarrow 01, C \rightarrow 10, D \rightarrow 11$

情報源モデル

情報源記号 $\{A, B, C, D\}$

$p(A)=0.25, p(B)=0.25, p(C)=0.25, p(D)=0.25$

平均符号長 = 2

符号アルファベット $\{0, 1\}$

平均符号長

情報源

情報源符号化

$A \rightarrow 00, B \rightarrow 01, C \rightarrow 10, D \rightarrow 11$

情報源モデル

情報源記号 $\{A, B, C, D\}$

$p(A)=0.6, p(B)=0.2, p(C)=0.1, p(D)=0.1$

平均符号長 = 2

符号アルファベット $\{0, 1\}$

平均符号長

情報源

情報源符号化

$A \rightarrow 0, B \rightarrow 01, C \rightarrow 10, D \rightarrow 11$

情報源モデル

情報源記号 $\{A, B, C, D\}$

$p(A)=0.6, p(B)=0.2, p(C)=0.1, p(D)=0.1$

$$\text{平均符号長} = 1 \times 0.6 + 2 \times 0.2 + 2 \times 0.1 + 2 \times 0.1 = 1.4$$

符号アルファベット $\{0, 1\}$

平均符号長さえ短ければいいのか？

情報源

情報源モデル

情報源記号 {A, B, C, D}

$p(A)=0.6$, $p(B)=0.2$ $p(C)=0.1$, $p(D)=0.1$

情報源符号化

$A \rightarrow 0$, $B \rightarrow 01$, $C \rightarrow 10$, $D \rightarrow 11$

ADA? BC?

0110

$$\text{平均符号長} = 1 \times 0.6 + 2 \times 0.2 + 2 \times 0.1 + 2 \times 0.1 = 1.4$$

符号アルファベット {0, 1}

符号化に課せられる条件

- 一意復号可能性
- 瞬時性

一意復号可能な符号

情報源

情報源符号化

$A \rightarrow 0, B \rightarrow 01, C \rightarrow 011, D \rightarrow 111$

情報源モデル

情報源記号 $\{A, B, C, D\}$

$p(A)=0.6, p(B)=0.2, p(C)=0.1, p(D)=0.1$

平均符号長 $= 1 \times 0.6 + 2 \times 0.2 + 3 \times 0.1 + 3 \times 0.1 = 1.6$

符号アルファベット $\{0, 1\}$

瞬時符号

情報源

情報源モデル

情報源記号 {A, B, C, D}

$p(A)=0.6, p(B)=0.2, p(C)=0.1, p(D)=0.1$

一意復号可能だが非瞬時

$A \rightarrow 0, B \rightarrow 01, C \rightarrow 011, D \rightarrow 111$

瞬時符号

$A \rightarrow 0, B \rightarrow 10, C \rightarrow 110, D \rightarrow 111$

$$\text{平均符号長} = 1 \times 0.6 + 2 \times 0.2 + 3 \times 0.1 + 3 \times 0.1 = 1.6$$

符号アルファベット {0, 1}

ここまでのまとめ

- Shannon-Fanoモデル
- いろいろな情報源
- 情報源のモデル化
- 情報源符号化
- 平均符号長
- 情報源符号の持つべき性質 — 一意復号可能性, 瞬時性

残った疑問

- 平均符号長はどこまで短くできるのか？
- 一意復号可能性の判定法？
- 瞬時符号の判定法？
- 平均符号長最短の符号(コンパクト符号)構成法？

...

符号の分類

- 符号語の長さによる分類
 - 等長符号
 - 非等長符号
- 復号の可能性による分類
 - 可逆符号
 - 瞬時符号
 - 非瞬時符号
 - 非可逆符号

情報源符号化のタイプ

(例) 各情報源記号ごとに符号語を割り当てる場合

| 情報源記号 | 符号 | | | | | | |
|--------|-----|-------|------|--------|-------|------|------|
| | C1 | C2 | C3 | C4 | C5 | C6 | C7 |
| A | 000 | 0 | 00 | 0 | 0 | 00 | 00 |
| B | 001 | 10 | 01 | 10 | 01 | 10 | 01 |
| C | 010 | 110 | 10 | 110 | 011 | 01 | 10 |
| D | 011 | 1110 | 110 | 1110 | 0111 | 011 | 111 |
| E | 100 | 11110 | 1110 | 11110 | 01111 | 0111 | 1110 |
| F | 101 | 11111 | 1111 | 111111 | 11111 | 1111 | 1111 |
| 等長／非等長 | 等長 | 非等長 | 非等長 | 非等長 | 非等長 | 非等長 | 非等長 |
| 瞬時符号 | ○ | ○ | ○ | ○ | × | × | × |
| 一意復号可能 | ○ | ○ | ○ | ○ | ○ | ○ | × |

瞬時性の判定

情報源

情報源符号化



符号アルファベット $\{0, 1\}$

符号1: 一意復号可能, 非瞬時

$A \rightarrow 0, B \rightarrow 01, C \rightarrow 011, D \rightarrow 111$

符号2: 瞬時

$A \rightarrow 0, B \rightarrow 10, C \rightarrow 110, D \rightarrow 111$

情報源モデル

情報源記号 $\{A, B, C, D\}$


$p(A)=0.6, p(B)=0.2, p(C)=0.1, p(D)=0.1$

$$\text{平均符号長} = 1 \times 0.6 + 2 \times 0.2 + 3 \times 0.1 + 3 \times 0.1 = 1.6$$


瞬時性の判定

符号の木: 符号化で使われる符号語の集合を構造的に表現したもの

$$C_1 = \{00, 010, 011, 10, 110, 111\}$$



$$C_2 = \{0, 01, 010, 10, 111\}$$



瞬時性の判定

- 符号の木で w_i が w_j の接頭

⇔

w_i が w_j の上流にある

- 符号の木 t が接頭条件を満足する

⇔

t のどの符号語も他の符号語の接頭になっていない.

- 符号化 C が瞬時符号である


⇔

C に対する符号の木が接頭条件を満足している.

瞬時性の判定


例： 情報源記号 $\{A_1, A_2, A_3, A_4, A_5\}$ に対する2元瞬時符号

「符号の木の原木」



接頭条件を満たす
ように枝刈りする


瞬時符号 P



瞬時性の判定


例： 情報源記号 $\{A_1, A_2, A_3, A_4, A_5\}$ に対する2元瞬時符号

瞬時符号 P




符号長バッグ: $\{1, 2, 3, 4, 5\}$

瞬時符号 Q



符号長バッグ: $\{3, 2, 3, 3, 4\}$

瞬時符号 R



符号長バッグ: $\{4, 4, 5, 4, 2\}$

瞬時符号構成可能な符号語バッグの条件？

瞬時符号構成可能性

クラフトの不等式

長さが l_1, l_2, \dots, l_M の M 個の符号語 c_1, c_2, \dots, c_M をもつ q 元瞬時符号を構成できる.

$$\Leftrightarrow q^{-l_1} + q^{-l_2} + \dots + q^{-l_M} \leq 1$$

例題: 長さ1,2,3,3の4個の符号語をもつ2元瞬時符号は構成可能か?

解答: Yes!

$$2^{-1} + 2^{-2} + 2^{-3} + 2^{-3} = \frac{4 + 2 + 1 + 1}{8} = 1 \leq 1$$

瞬時符号構成可能性

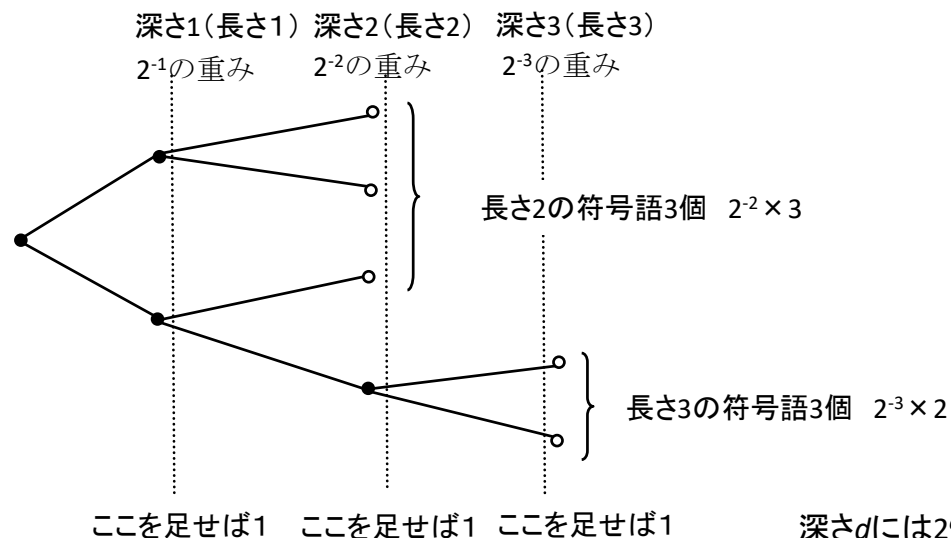
クラフトの不等式

長さが l_1, l_2, \dots, l_M の M 個の符号語 c_1, c_2, \dots, c_M をもつ q 元瞬時符号を構成できる.

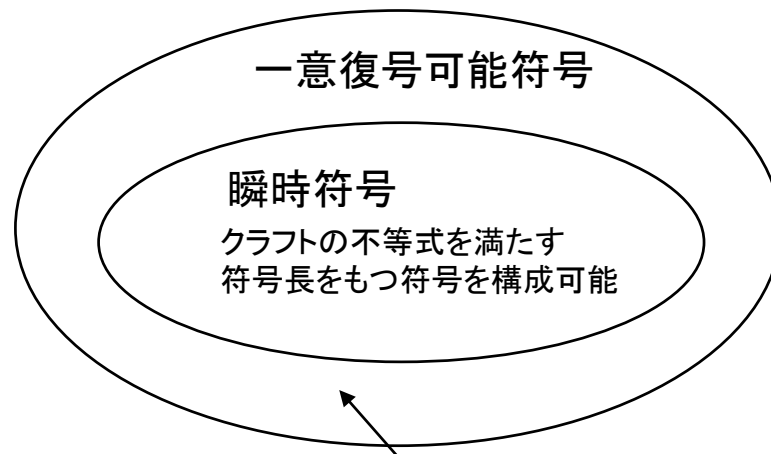
$$\Leftrightarrow q^{-l_1} + q^{-l_2} + \dots + q^{-l_M} \leq 1$$

直観的証明: リソースという考え方を使う

2元符号の場合



一意復号可能な符号の構成可能性



クラフトの不等式を満たさない符号長をもつ一意復元可能な符号を構成可能？

⇒ NO!

マクミランの不等式

l_1, l_2, \dots, l_M の M 個の符号語 c_1, c_2, \dots, c_M をもつ q 元一意復号可能な符号を構成できる.

$$\Leftrightarrow q^{-l_1} + q^{-l_2} + \dots + q^{-l_M} \leq 1$$

マクミランの不等式の証明

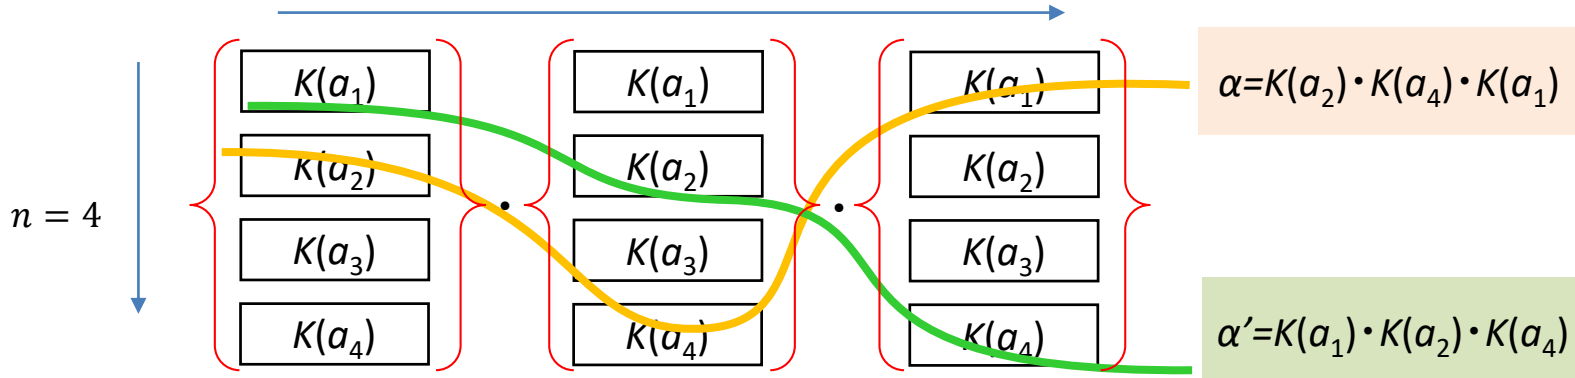
- a_1, a_2, \dots, a_n を情報源記号, $K(a_1), K(a_2), \dots, K(a_n)$ を符号語, d_1, d_2, \dots, d_n を各符号語の長さとする.
- $c = 2^{-d_1} + 2^{-d_2} + \dots + 2^{-d_n}$ という量に着目し, $c > 1$ ならば, 一意に復号可能でないことを示す.
- c^m という量について考えてみよう.
 c^m は $\{c_1, c_2, \dots, c_n\}$ のなかの符号語を m 個つないでできるすべての系列 α について, $2^{-|\alpha|}$ を計算し, 加えたものに等しい.

(例) $n = 4, m = 3$

$$\begin{aligned}
 c^3 &= (2^{-d_1} + 2^{-d_2} + 2^{-d_3} + 2^{-d_4}) \times (2^{-d_1} + 2^{-d_2} + 2^{-d_3} + 2^{-d_4}) \times (2^{-d_1} + 2^{-d_2} + 2^{-d_3} + 2^{-d_4}) \\
 &= 2^{-(d_1+d_1+d_1)} + 2^{-(d_1+d_1+d_2)} + 2^{-(d_1+d_1+d_3)} + \dots + 2^{-(d_4+d_4+d_3)} + 2^{-(d_4+d_4+d_4)} \\
 &= \sum_{\substack{3 \cdot \min_{1 \leq i \leq 4} d_i \leq l \leq 3 \cdot \max_{1 \leq i \leq 4} d_i}} N_l \cdot 2^{-l}
 \end{aligned}$$

一般には, $c^m = \sum_{\substack{m \cdot \min_{1 \leq i \leq n} d_i \leq l \leq m \cdot \max_{1 \leq i \leq n} d_i}} N_l \cdot 2^{-l}$

$m = 3$



マクミランの不等式の証明

- 所与の符号が一意復号可能であるためには、長さ l になる系列の個数 N_l は、長さ l の可能な2元符号語の個数 2^l を超えてはならない。つまり、 $N_l \leq 2^l$ でなければならない。

- 従って、
$$c^m = \sum_{m \cdot \min_{1 \leq i \leq n} d_i \leq l \leq m \cdot \max_{1 \leq i \leq n} d_i} N_l \cdot 2^{-l} \leq \sum_{m \cdot \min_{1 \leq i \leq n} d_i \leq l \leq m \cdot \max_{1 \leq i \leq n} d_i} 2^l \cdot 2^{-l} \leq m \cdot \max_{1 \leq i \leq n} d_i$$

- 前項で得られた $N_l \leq 2^l$ は、(固定された l_1, l_2, \dots, l_n に対して)任意の m について成立しなければならない。

- ここで

$$\frac{c^m}{m} = \frac{((c-1) + 1)^m}{m} = \frac{1 + m(c-1) + \frac{m(m-1)(c-1)^2}{2} + \dots}{m} > \frac{(m-1)(c-1)^2}{2}$$

であるので、 $c > 1$ であればこの条件を満足できない。

- 従って、 $c \leq 1$ でなければならない。

まとめ

- Shannon-Fanoモデル
- いろいろな情報源
- 情報源のモデル化
- 情報源符号化
- 平均符号長
- 情報源符号の持つべき性質 — 一意復号可能性, 瞬時性
- 瞬時性の判定 — 接頭条件
- 瞬時符号構成可能性 — クラフトの不等式
- 一意復号可能な符号の構成可能性 — マクミランの不等式
- 残された課題: 平均符号長はどこまで短くできるのか? 一意復号可能性の判定法? 平均符号長最短の符号の構成法?