

平均符号長の限界と 情報源符号化定理

情報源の1次エントロピー

- 情報源 S :
 - 情報源記号 $A = \{a_1, \dots, a_M\}$
 - 各情報源記号の発生確率 $P(a_i) = p_i$
- 情報源符号化
 - 情報源記号 a_i の符号化 $K(a_i) = c_i$
 - 1情報源記号あたりの平均符号長 $L = p_1 l_1 + \dots + p_M l_M$
ここで, $l_i = |c_i|$
- 情報源 S の1次エントロピー

$$H_1(S) = \sum_{i=1}^M p_i \log_2 \frac{1}{p_i} = - \sum_{i=1}^M p_i \log_2 p_i$$

情報源の1次エントロピー

【補助定理3】

p_1, \dots, p_M を $p_1 + \dots + p_M = 1$ となる非負の数, q_1, \dots, q_M を $q_1 + \dots + q_M \leq 1$ となる非負の数とする. $p_i \neq 0$ のとき, $q_i \neq 0$ とすれば,

$$-\sum_{i=1}^M p_i \log_2 q_i \geq -\sum_{i=1}^M p_i \log_2 p_i$$

が成立する. 等号はすべての*i*について $q_i = p_i$ のときに限り成立する.

【補助定理3】の適用例

$$(p_1, p_2, p_3, p_4, p_5)$$

$$(0.6, 0.2, 0.1, 0.07, 0.03)$$

$$-\sum_{i=1}^M p_i \log_2 q_i$$

$$(q_1, q_2, q_3, q_4, q_5)$$

$$(0.2, 0.2, 0.2, 0.2, 0.2)$$

$$\approx 2.32193$$

$$(0.9, 0.025, 0.025, 0.025, 0.025)$$

$$\approx 2.21997$$

$$(0.6, 0.2, 0.1, 0.07, 0.03)$$

$$\approx 1.65908$$

情報源の1次エントロピー

【補助定理3】

p_1, \dots, p_M を $p_1 + \dots + p_M = 1$ となる非負の数, q_1, \dots, q_M $q_1 + \dots + q_M \leq 1$ となる非負の数とする。 $p_i \neq 0$ のとき, $q_i \neq 0$ とすれば,

$$-\sum_{i=1}^M p_i \log_2 q_i \geq -\sum_{i=1}^M p_i \log_2 p_i$$

が成立する。等号はすべての i について $q_i = p_i$ のときに限り成立する。

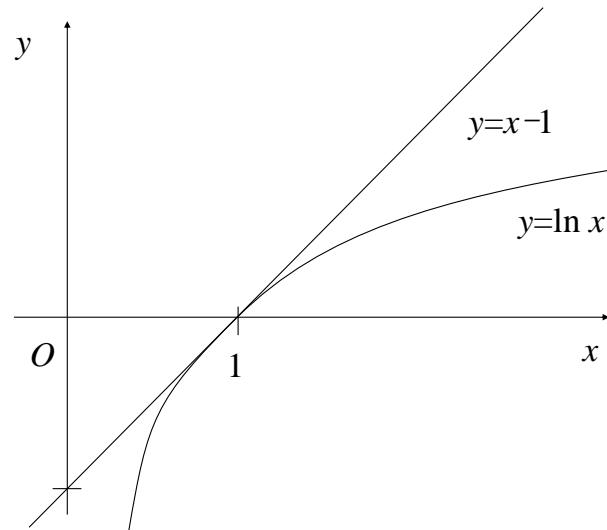
【補助定理3】の証明の骨子

$$D = -\sum_{i=1}^M p_i \log_2 q_i + \sum_{i=1}^M p_i \log_2 p_i = -\sum_{i=1}^M p_i \log_2 \frac{q_i}{p_i} = -\sum_{i=1}^M \frac{p_i}{\ln 2} \ln \frac{q_i}{p_i}$$

と置く。 $\ln x \leq x - 1$ であることを利用すると、

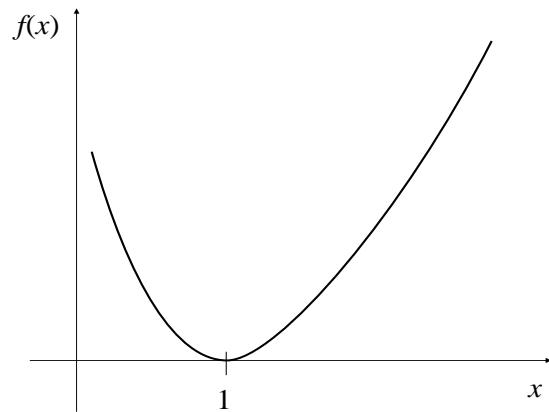
$$D = -\sum_{i=1}^M \frac{p_i}{\ln 2} \ln \frac{q_i}{p_i} \geq -\sum_{i=1}^M \frac{p_i}{\ln 2} \left(\frac{q_i}{p_i} - 1 \right) = \frac{1}{\ln 2} \sum_{i=1}^M (p_i - q_i) = \frac{1}{\ln 2} \left(\sum_{i=1}^M p_i - \sum_{i=1}^M q_i \right) \geq 0$$

情報源の1次エントロピー



$$\ln x \leq x - 1$$

$$f(x) = x - 1 - \ln x$$



$$f(1) = 0, f'(x) = 1 - \frac{1}{x}$$

情報源の1次エントロピー

【定理】

情報源 S の各情報源記号を一意復号可能な2元符号に符号化すると、平均符号長 L は、 $H_1(S) \leq L$ を満足する。

また、平均符号長 L が $L < H_1(S) + 1$ となる瞬時符号を作ることができる。

情報源の1次エントロピー

【定理】の証明の骨子 (前半: $H_1(S) \leq L$ の証明)

- $q_i = 2^{-l_i}$ と置く (q_i を導入する).
- 一意復号可能な情報源符号は, l_1, l_2, \dots, l_M はマクミランの不等式を満足するので, $2^{-l_1} + 2^{-l_2} + \dots + 2^{-l_M} \leq 1$. つまり, $q_1 + \dots + q_M \leq 1$ が満足される. また, $q_i > 0$ も明らか.
- 従って補助定理から, $-\sum_{i=1}^M p_i \log_2 q_i \geq -\sum_{i=1}^M p_i \log_2 p_i = H_1(S)$ となる.
- 左辺は, $-\sum_{i=1}^M p_i \log_2 q_i = -\sum_{i=1}^M p_i \log_2 2^{-l_i} = \sum_{i=1}^M p_i l_i = L$ である. 等号が成立するのは, 全ての i について, $p_i = 2^{-l_i}$ のときである. ■

情報源の1次エントロピー

【定理】の証明の骨子（後半： $L < H_1(S) + 1$ を満足する瞬時符号が構成可能）

- $-\log_2 p_i \leq l_i < -\log_2 p_i + 1$ なる整数 l_i が一意に決まる.
- 得られた l_i に対して $2^{-l_i} \leq 2^{\log_2 p_i} = p_i$ が成りたつ.
- $\sum 2^{-l_i} \leq \sum p_i = 1$ となり, クラフトの不等式が満たされたので, l_i を符号長バッゲとする瞬時符号をつくることができる.
- $L = \sum_{i=1}^M p_i l_i$ であるので,
この符号の平均符号長は, $-p_i \log_2 p_i \leq p_i l_i < -p_i \log_2 p_i + p_i$ つまり,
 $H_1(S) \leq L < H_1(S) + 1$ が満足される. ■

定理の意味すること

情報源S: $\langle A: 0.6, B: 0.2, C: 0.1, D: 0.07, E: 0.03 \rangle$

$$\begin{aligned}H_1(S) &= -(0.6\log_2 0.6 + 0.2\log_2 0.2 + 0.1\log_2 0.1 + 0.07\log_2 0.07 + 0.03\log_2 0.03) \\&\approx 1.65908\end{aligned}$$

平均符号長が1.65908～2.65908となる瞬時符号を構成可能.

しかしこの定理は、そのような瞬時符号の構成法を教えてくれるわけではない。

⇒ ハフマン符号化などを用いてコンパクト符号を計算する。

$\langle A \rightarrow 0, B \rightarrow 10, C \rightarrow 110, D \rightarrow 1110, E \rightarrow 1111 \rangle$ はコンパクト符号で平均符号長1.7

情報源記号ごとに符号化するかぎり、平均符号長を理論的下限に近づけることはできない

拡大情報源

- q 元情報源 S の n 次の拡大情報源 S^n : S の連続する n 個の情報源記号列を情報源記号とする q^n 元情報源.

- 無記憶情報源 S の連続する n 個の出力は互いに独立であるから、その結合確率分布は、

$$P(x_0, x_1, \dots, x_{n-1}) = P(x_0)P(x_1) \cdots P(x_{n-1})$$

となる。

- 無記憶情報源 S の n 次拡大情報源を S^n とすれば、

$$H_1(S^n) = nH_1(S)$$

が成り立つ。

拡大情報源

$$\begin{aligned} H_1(S^n) = nH_1(S) \text{になるわけ } &\Rightarrow H_1(S^3) \\ &= -\sum_{x_0} \sum_{x_1} \sum_{x_2} P(x_0, x_1, x_2) \log_2 P(x_0, x_1, x_2) \\ &= -\sum_{x_0} \sum_{x_1} \sum_{x_2} P(x_0)P(x_1)P(x_2) \log_2 (P(x_0)P(x_1)P(x_2)) \\ &= -\sum_{x_0} \sum_{x_1} \sum_{x_2} P(x_0)P(x_1)P(x_2) \log_2 P(x_0) \\ &\quad - \sum_{x_0} \sum_{x_1} \sum_{x_2} P(x_0)P(x_1)P(x_2) \log_2 P(x_1) \\ &\quad - \sum_{x_0} \sum_{x_1} \sum_{x_2} P(x_0)P(x_1)P(x_2) \log_2 P(x_2) \\ &= -\sum_{x_0} P(x_0) \log_2 P(x_0) \\ &\quad - \sum_{x_1} P(x_1) \log_2 P(x_1) \\ &\quad - \sum_{x_2} P(x_2) \log_2 P(x_2) \\ &= 3H_1(S) \end{aligned}$$

計算の様子 (1/2)

$$\begin{aligned}
 & P(A)P(D)P(G)\log_2P(A) & P(A)P(D)P(G)\log_2P(D) & P(A)P(D)P(G)\log_2P(G) \\
 & P(A)P(D)P(H)\log_2P(A) & P(A)P(D)P(H)\log_2P(D) & P(A)P(D)P(H)\log_2P(H) \\
 & P(A)P(D)P(I)\log_2P(A) & P(A)P(D)P(I)\log_2P(D) & P(A)P(D)P(I)\log_2P(I) \\
 & P(A)P(E)P(G)\log_2P(A) & P(A)P(E)P(G)\log_2P(E) & P(A)P(E)P(G)\log_2P(G) \\
 & P(A)P(E)P(H)\log_2P(A) & P(A)P(E)P(H)\log_2P(E) & P(A)P(E)P(H)\log_2P(H) \\
 & P(A)P(E)P(I)\log_2P(A) & P(A)P(E)P(I)\log_2P(E) & P(A)P(E)P(I)\log_2P(I) \\
 & P(A)P(F)P(G)\log_2P(A) & P(A)P(F)P(G)\log_2P(F) & P(A)P(F)P(G)\log_2P(G) \\
 & P(A)P(F)P(H)\log_2P(A) & P(A)P(F)P(H)\log_2P(F) & P(A)P(F)P(H)\log_2P(H) \\
 & P(A)P(F)P(I)\log_2P(A) & P(A)P(F)P(I)\log_2P(F) & P(A)P(F)P(I)\log_2P(I) \\
 & P(B)P(D)P(G)\log_2P(B) & P(B)P(D)P(G)\log_2P(D) & P(B)P(D)P(G)\log_2P(G) \\
 & P(B)P(D)P(H)\log_2P(B) & P(B)P(D)P(H)\log_2P(D) & P(B)P(D)P(H)\log_2P(H) \\
 & P(B)P(D)P(I)\log_2P(B) & P(B)P(D)P(I)\log_2P(D) & P(B)P(D)P(I)\log_2P(I) \\
 & P(B)P(E)P(G)\log_2P(B) & P(B)P(E)P(G)\log_2P(E) & P(B)P(E)P(G)\log_2P(G) \\
 & P(B)P(E)P(H)\log_2P(B) & P(B)P(E)P(H)\log_2P(E) & P(B)P(E)P(H)\log_2P(H) \\
 & P(B)P(E)P(I)\log_2P(B) & P(B)P(E)P(I)\log_2P(E) & P(B)P(E)P(I)\log_2P(I) \\
 & P(B)P(F)P(G)\log_2P(B) & P(B)P(F)P(G)\log_2P(F) & P(B)P(F)P(G)\log_2P(G) \\
 & P(B)P(F)P(H)\log_2P(B) & P(B)P(F)P(H)\log_2P(F) & P(B)P(F)P(H)\log_2P(H) \\
 & P(B)P(F)P(I)\log_2P(B) & P(B)P(F)P(I)\log_2P(F) & P(B)P(F)P(I)\log_2P(I) \\
 & P(C)P(D)P(G)\log_2P(C) & P(C)P(D)P(G)\log_2P(D) & P(C)P(D)P(G)\log_2P(G) \\
 & P(C)P(D)P(H)\log_2P(C) & P(C)P(D)P(H)\log_2P(D) & P(C)P(D)P(H)\log_2P(H) \\
 & P(C)P(D)P(I)\log_2P(C) & P(C)P(D)P(I)\log_2P(D) & P(C)P(D)P(I)\log_2P(I) \\
 & P(C)P(E)P(G)\log_2P(C) & P(C)P(E)P(G)\log_2P(E) & P(C)P(E)P(G)\log_2P(G) \\
 & P(C)P(E)P(H)\log_2P(C) & P(C)P(E)P(H)\log_2P(E) & P(C)P(E)P(H)\log_2P(H) \\
 & P(C)P(E)P(I)\log_2P(C) & P(C)P(E)P(I)\log_2P(E) & P(C)P(E)P(I)\log_2P(I) \\
 & P(C)P(F)P(G)\log_2P(C) & P(C)P(F)P(G)\log_2P(F) & P(C)P(F)P(G)\log_2P(G) \\
 & P(C)P(F)P(H)\log_2P(C) & P(C)P(F)P(H)\log_2P(F) & P(C)P(F)P(H)\log_2P(H) \\
 & P(C)P(F)P(I)\log_2P(C) & P(C)P(F)P(I)\log_2P(F) & P(C)P(F)P(I)\log_2P(I)
 \end{aligned}$$

$$\sum = \sum \begin{pmatrix} P(A)\log_2P(A) \\ P(B)\log_2P(B) \\ P(C)\log_2P(C) \end{pmatrix} + \sum \begin{pmatrix} P(D)\log_2P(D) \\ P(E)\log_2P(E) \\ P(F)\log_2P(F) \end{pmatrix} + \sum \begin{pmatrix} P(G)\log_2P(G) \\ P(H)\log_2P(H) \\ P(I)\log_2P(I) \end{pmatrix}$$

$$\sum = \sum \begin{pmatrix} \cancel{P(D)P(G)} \\ \cancel{P(D)P(H)} \\ \cancel{P(D)P(I)} \\ \cancel{P(E)P(G)} \\ \cancel{P(E)P(H)} \\ \cancel{P(E)P(I)} \\ \cancel{P(F)P(G)} \\ \cancel{P(F)P(H)} \\ \cancel{P(F)P(I)} \end{pmatrix} + \sum \begin{pmatrix} \cancel{P(A)P(G)} \\ \cancel{P(A)P(H)} \\ \cancel{P(A)P(I)} \\ \cancel{P(B)P(G)} \\ \cancel{P(B)P(H)} \\ \cancel{P(B)P(I)} \\ \cancel{P(C)P(G)} \\ \cancel{P(C)P(H)} \\ \cancel{P(C)P(I)} \end{pmatrix} + \sum \begin{pmatrix} \cancel{P(A)P(D)} \\ \cancel{P(A)P(E)} \\ \cancel{P(A)P(F)} \\ \cancel{P(B)P(D)} \\ \cancel{P(B)P(E)} \\ \cancel{P(B)P(F)} \\ \cancel{P(C)P(D)} \\ \cancel{P(C)P(E)} \\ \cancel{P(C)P(F)} \end{pmatrix}$$

$$\sum \begin{pmatrix} P(D)P(G) \\ P(D)P(H) \\ P(D)P(I) \\ P(E)P(G) \\ P(E)P(H) \\ P(E)P(I) \\ P(F)P(G) \\ P(F)P(H) \\ P(F)P(I) \end{pmatrix} = (P(D) + P(E) + P(F)) \times (P(G) + P(H) + P(I)) = 1$$

ブロック符号化

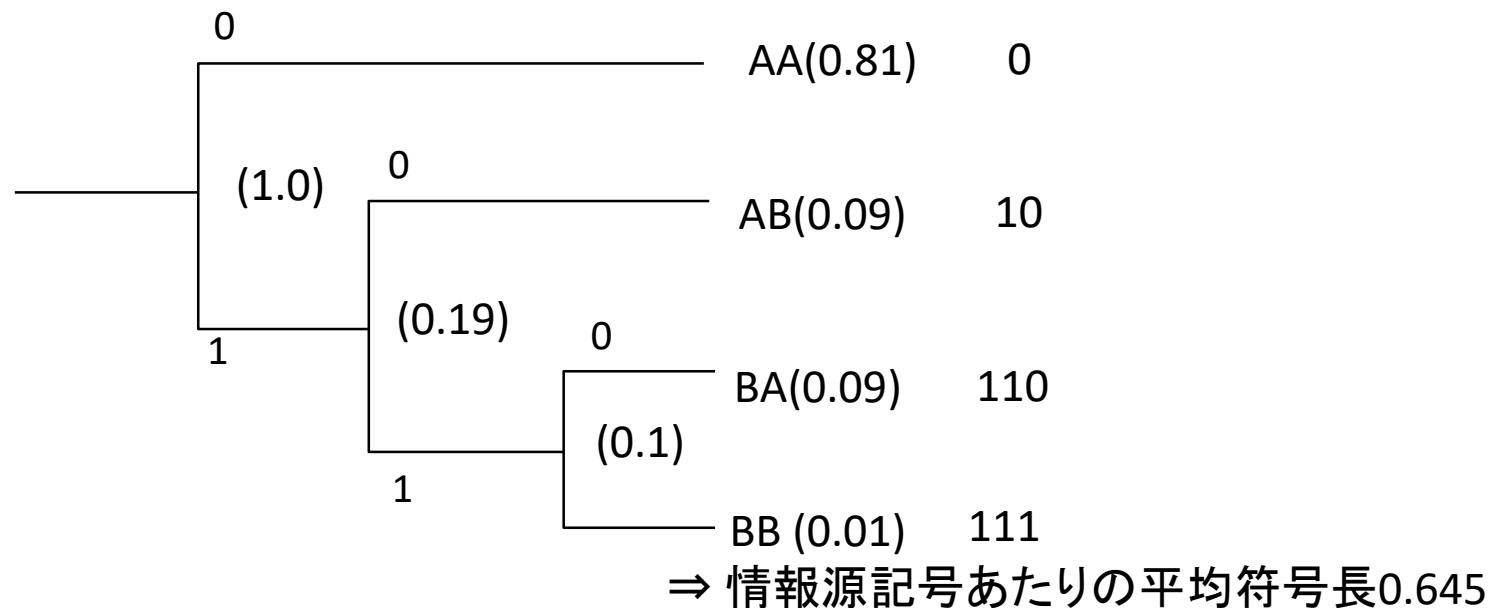
- ブロック符号化: 情報源から発生する記号をまとめて符号化する方法.
- ブロック符号化することによって, 平均符号長を情報源エントロピーに近づけることができる.

ブロック符号化

⟨A: 0.9, B: 0.1⟩に対するハフマン符号化



⟨AA: 0.81, AB: 0.09, BA: 0.09, BB: 0.01⟩に対するハフマン符号化



ブロック符号化

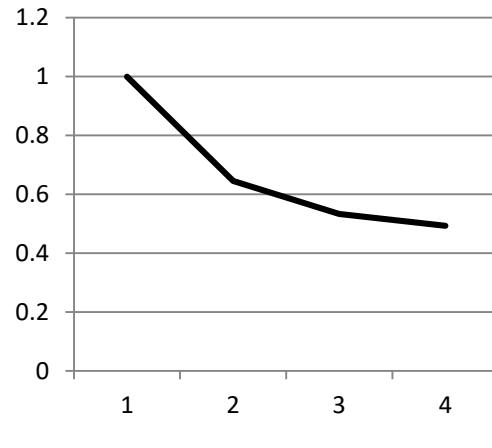
⟨A: 0.9, B: 0.1⟩の3次拡大情報源に対するハフマン符号化

AAA:	0.729	0
AAB:	0.081	100
ABA:	0.081	101
BAA:	0.081	110
ABB:	0.009	11100
BAB:	0.009	11101
BBA:	0.009	11110
BBB:	0.001	11111

⇒ 情報源記号あたりの平均符号長約0.53267

ブロック符号化の威力

情報源記号あたり平均符号長



ブロック長を大きくしたらどうなるか？

情報源符号化定理

情報源 S について、

$$H_1(S^n) \leq L_n < H_1(S^n) + 1$$

が成立する。

情報源 S の n 次の拡張 S^n についても、

$$H_1(S^n) \leq L_n < H_1(S^n) + 1$$

ここで、 L_n は S の 1 記号あたりの平均符号長。 S が無記憶であれば

$$H_1(S^n) = nH_1(S)$$

また、 $L_n = nL$ なので、

$$H_1(S) \leq L < H_1(S) + \frac{1}{n}$$

→ ブロック符号化によって、平均符号長を $H_1(S)$ に限りなく近づけられる

情報源符号化定理

【情報源符号化定理】

情報源 S は、任意の正数 ε に対して、1情報源記号あたりの平均符号長 L が、

$$H(S) \leq L < H(S) + \varepsilon$$

となるような2元瞬時符号に符号化できる。

他方、どのような一意復号可能な2元符号を用いても、平均符号長がこの式の左辺より小さくなる符号化はできない。

情報源符号化定理

情報源 S のエントロピー— $H(S)$ ：

$$H(S) \equiv \lim_{n \rightarrow \infty} H_n(S) = \lim_{n \rightarrow \infty} \frac{H_1(S^n)}{n}$$

ここで、 $H_1(S^n) = -\sum \cdots \sum P(x_0, \dots, x_{n-1}) \log_2 P(x_0, \dots, x_{n-1})$
は S の n 次の拡大情報源 S^n の1次エントロピー.

$H_n(S) \equiv \frac{H_1(S^n)}{n}$ は S の1情報源記号あたりの n 次エントロピー.

一般には、 $H(S) \leq H_n(S)$ であることが知られている.

まとめ

- 情報源の1次エントロピー
- 補助定理3
- 情報源記号ごとに瞬時符号を構成した場合の平均符号長の下限
- 拡大情報源とその1次エントロピー
- ブロック符号化: 情報源から発生する記号をまとめて符号化する方法.
- ブロック符号化をすることによって, 平均符号長を情報源エントロピーに近づけることができる.
- 情報源符号化定理